

TAREA 1

CIENCIA DE DATOS

Brain de Jesús Salazar, César Ávila, Iván García

12 de septiembre de 2025

Solución del problema 1.

Solución del problema 2. Considere el modelo de regresión lineal $\mathbf{Y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ donde $\boldsymbol{\varepsilon} \sim N_n(\mathbf{0}, \sigma^2 I)$. Del ejercicio anterior se sabe que la matriz

$$H = X(X^T X)^{-1} X^T,$$

es una matriz de proyección ortogonal. Usando la descomposición espectral, se puede descomponer a H de la forma

$$H = RR^T,$$

basta con reescribir a la matriz diagonal como el producto de dos matrices donde cada matriz tiene en su diagonal a la raíz cuadrada de cada elemento. Por otro lado, observe que ya que H es idempotente se tiene que

$$H^2 = (RR^T)(RR^T) = H = RR^T,$$

por lo que

$$R^T R = I_p.$$

Por otro lado, note que por la propiedad cíclica de la traza

$$\text{tr}(H) = \text{tr}(RR^T) = \text{tr}(R^T R) = \text{tr}(I_p) = p.$$

Por lo tanto,

$$\sum_{i=1}^n h_{ii} = p.$$

Solución del problema 3. Considere el modelo de regresión lineal clásico, $\mathbf{Y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ donde $\boldsymbol{\varepsilon} \sim N_n(\mathbf{0}, \sigma^2 I)$ y a la matriz de proyección ortogonal,

$$H = X(X^T X)^{-1} X^T.$$

Se sabe que el vector de residuos se puede expresar como

$$\mathbf{e} = (I - H)\mathbf{Y},$$

luego ya que \mathbf{Y} sigue una distribución normal multivariada con media $X\boldsymbol{\beta}$ y varianza $\sigma^2 I_n$, se tiene que,

$$\mathbf{e} \sim N_n(\mathbf{0}, \sigma^2 (I_n - H)).$$

De lo anterior, se tiene que

$$e_i \sim N(0, \sigma^2(1 - h_{ii})).$$

y normalizando,

$$\frac{e_i}{\sigma\sqrt{1 - h_{ii}}} \sim N(0, 1)$$

Por otro lado, observe que si se considera a el estimador insesgado de la varianza,

$$\hat{\sigma}^2 = \frac{\mathbf{e}^\top \mathbf{e}}{n - p} = \frac{\sigma^2 \mathbf{Y}^\top (I - H) \mathbf{Y}}{\sigma^2 (n - p)},$$

y se observa que $(I - H)$ es una matriz idempotente de rango $n - p$ se tiene que

$$\frac{(n - p)}{\sigma^2} \hat{\sigma}^2 = \frac{\mathbf{Y}^\top (I - H) \mathbf{Y}}{\sigma^2} \sim \chi^2(n - p).$$

Por ultimo, se sabe que una variable aleatoria t de Student con r grados de libertad se define como la razón entre una variable aleatoria normal estándar sobre la raíz cuadrada de una variable chi cuadrada dividida entre sus r grados, con las variables aleatorias independientes. Ya que en este caso la normal estándar no es independiente de la chi cuadrada se tiene que la siguiente variable aleatoria cumple que aproximadamente,

$$\frac{\frac{e_i}{\sigma\sqrt{1 - h_{ii}}}}{\sqrt{\frac{(n - p)}{(n - p)\sigma^2} \hat{\sigma}^2}} \sim t(n - p).$$

Simplificando la expresión de la izquierda se tiene,

$$r_i = \frac{e_i}{\hat{\sigma}\sqrt{1 - h_{ii}}} \sim t(n - p).$$

Para arreglar el problema de la independencia se propone estimar a σ^2 sin usar el i -ésimo dato, es decir

$$\hat{\sigma}_i^2 = \frac{\mathbf{e}_i^\top \mathbf{e}_i}{n-1-p} = \frac{\sigma^2 \mathbf{Y}_i^\top (I - H_i) \mathbf{Y}_i}{\sigma^2 (n-1-p)},$$

donde el vector \mathbf{Y}_i se obtiene eliminando al i -ésima entrada y H_i se construye eliminando la i -ésima entrada de X . En este caso la matriz $(I - H_i)$ es idempotente de rango $n-1-p$, por lo que,

$$\frac{(n-1-p)}{\sigma^2} \hat{\sigma}_i^2 = \frac{\mathbf{Y}_i^\top (I - H_i) \mathbf{Y}_i}{\sigma^2} \sim \chi^2(n-1-p).$$

Como en este caso $\hat{\sigma}_i$ no depende de e_i se tiene que es independiente de la normal estandar definida previamente, de aquí se cumple que,

$$\frac{\frac{e_i}{\sigma \sqrt{1-h_{ii}}}}{\sqrt{\frac{(n-1-p)}{(n-1-p)\sigma^2} \hat{\sigma}_i^2}} \sim t(n-1-p).$$

Simplificando el lado derecho se tiene que,

$$r_i = \frac{e_i}{\hat{\sigma}_i \sqrt{1-h_{ii}}} \sim t(n-p-1).$$

Solución del problema 4.

Solución del problema 5. Consideremos una muestra Y_1, \dots, Y_n de variables aleatorias independientes e idénticamente distribuidas con media μ y varianza σ^2 , con indicadores $R_i \in \{0, 1\}$, de tal manera que $R_i \perp Y_i$ para cada $i \in \{1, \dots, n\}$. Dichas R_i existen pues estamos bajo el modelo MCAR, y se interpretan como $R_i = 1$ si y solo si el dato Y_i fue observado.

Notemos que si n_{obs} representa el número de datos observados, entonces $n_{obs} = \sum_{i=1}^n R_i$. Además, por la definición de los R_i ,

$$\bar{Y}_{obs} = \frac{1}{n_{obs}} \sum_{i=1}^n R_i Y_i = \frac{1}{n_{obs}} \sum_{i: R_i=1} Y_i.$$

Así pues, si $\mathbf{R} = (R_1, \dots, R_n)$, entonces

$$\begin{aligned} \mathbb{E} [\bar{Y}_{obs} \mid \mathbf{R}] &= \mathbb{E} \left[\frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n R_i Y_i \mid \mathbf{R} \right] = \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n \mathbb{E} [R_i Y_i \mid \mathbf{R}] \\ &= \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n R_i \mathbb{E} [Y_i \mid \mathbf{R}] \\ &= \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n R_i \mathbb{E} [Y_i] \\ &= \mu, \end{aligned}$$

en donde hemos usado que las Y_i son iid con media μ y son independientes de \mathbf{R} (por las hipótesis del modelo MCAR). Por consiguiente,

$$\mathbb{E} [\bar{Y}_{obs}] = \mathbb{E} [\mathbb{E} [\bar{Y}_{obs} \mid \mathbf{R}]] = \mu.$$

Por otra parte,

$$\bar{Y}_{obs}^2 = \frac{1}{(\sum_{i=1}^n R_i)^2} \left[\sum_{i=1}^n R_i^2 Y_i^2 + \sum_{i \neq j} R_i R_j Y_i Y_j \right],$$

por lo que

$$\begin{aligned} \mathbb{E} [\bar{Y}_{obs}^2 \mid \mathbf{R}] &= \frac{1}{(\sum_{i=1}^n R_i)^2} \left[\sum_{i=1}^n R_i^2 \mathbb{E} [Y_i^2 \mid \mathbf{R}] + \sum_{i \neq j} R_i R_j \mathbb{E} [Y_i Y_j \mid \mathbf{R}] \right] \\ &= \frac{1}{(\sum_{i=1}^n R_i)^2} \left[\sum_{i=1}^n R_i^2 \mathbb{E} [Y_i^2] + \sum_{i \neq j} R_i R_j \mathbb{E} [Y_i Y_j] \right] \\ &= \frac{1}{(\sum_{i=1}^n R_i)^2} \left[(\sigma^2 + \mu^2) \sum_{i=1}^n R_i^2 + \mu^2 \sum_{i \neq j} R_i R_j \right] \\ &= \mu^2 + \sigma^2 \frac{\sum_{i=1}^n R_i^2}{(\sum_{i=1}^n R_i)^2}. \end{aligned}$$

De lo anterior se sigue que

$$\begin{aligned}
 \text{Var} [\bar{Y}_{obs}] &= \mathbb{E} [\bar{Y}_{obs}^2] - (\mathbb{E} [\bar{Y}_{obs}])^2 = \mathbb{E} [\mathbb{E} [\bar{Y}_{obs}^2 \mid \mathbf{R}]] - \mu^2 = \sigma^2 \mathbb{E} \left[\frac{\sum_{i=1}^n R_i^2}{(\sum_{i=1}^n R_i)^2} \right] \\
 &= \sigma^2 \mathbb{E} \left[\frac{\sum_{i=1}^n R_i}{(\sum_{i=1}^n R_i)^2} \right] \\
 &= \sigma^2 \mathbb{E} \left[\frac{1}{\sum_{i=1}^n R_i} \right] \\
 &= \sigma^2 \mathbb{E} \left[\frac{1}{n_{obs}} \right] \\
 &\geq \frac{\sigma^2}{n} = \text{Var} [\bar{Y}] ,
 \end{aligned}$$

en donde hemos usado que $R_i^2 = R_i$, pues $R_i \in \{0, 1\}$, para todo $i \in \{1, \dots, n\}$, y que $n_{obs} \leq n$. De hecho, siguiendo un procedimiento completamente análogo, pero ahora con varianzas condicionales, se sigue que

$$\text{Var} [\bar{Y}_{obs} \mid \mathbf{R}] = \frac{\sigma^2}{n_{obs}}.$$

De lo anterior podemos notar que \bar{Y}_{obs} es insesgado, pero que $\text{Var} [\bar{Y}_{obs}] \geq \text{Var} [\bar{Y}]$, por lo que \bar{Y}_{obs} tiene menor eficiencia (posee más varianza, pues la eliminación de datos hace que haya menos de ellos para poder estimar a la media de Y).

Solución del problema 6. Sean $\mathbf{Y} = (Y_{obs}, Y_{mis})$ y \mathbf{R} el patrón de datos faltantes. Bajo la definición del MAR,

$$\mathbb{P}[\mathbf{R} | Y_{obs}, Y_{mis}, \theta, \psi] = \mathbb{P}[\mathbf{R} | Y_{obs}, \psi].$$

Así pues, bajo este modelo,

$$\mathbb{P}[\mathbf{Y}, \mathbf{R} | \theta, \psi] = \mathbb{P}[\mathbf{Y} | \theta] \mathbb{P}[\mathbf{R} | \mathbf{Y}, \psi] = \mathbb{P}[\mathbf{Y} | \theta] \mathbb{P}[\mathbf{R} | Y_{obs}, \psi].$$

Por consiguiente, la verosimilitud de θ está dada por

$$\begin{aligned} L(\theta; Y_{obs}, \mathbf{R}) &= \int \mathbb{P}[\mathbf{Y}, \mathbf{R} | \theta, \psi] dY_{mis} = \int \mathbb{P}[\mathbf{Y} | \theta] \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] dY_{mis} \\ &= \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \int \mathbb{P}[\mathbf{Y} | \theta] dY_{mis} \\ &= \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \mathbb{P}[Y_{obs} | \theta]. \end{aligned}$$

Ya que el factor $\mathbb{P}[\mathbf{R} | Y_{obs}, \psi]$ no depende de θ , se sigue que $L(\theta; Y_{obs}, \mathbf{R}) \propto \mathbb{P}[Y_{obs} | \theta]$. Para ver las condiciones *a priori* que garantizan ignorabilidad bajo el enfoque bayesiano, notemos que

$$\begin{aligned} \mathbb{P}[\theta | Y_{obs}, \mathbf{R}] &= \int \mathbb{P}[\theta, \psi | Y_{obs}, \mathbf{R}] d\psi \propto \int \mathbb{P}[Y_{obs}, \mathbf{R} | \theta, \psi] \pi(\theta, \psi) d\psi \\ &= \int \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \mathbb{P}[Y_{obs} | \theta] \pi(\theta, \psi) d\psi \\ &= \mathbb{P}[Y_{obs} | \theta] \int \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \pi(\theta, \psi) d\psi. \end{aligned}$$

Para concluir ignorabilidad buscamos que $L(\theta | Y_{obs}, \mathbf{R}) \propto \pi(\theta) \mathbb{P}[Y_{obs} | \theta]$, y ya que la integral anterior depende de θ solamente a través del factor $\pi(\theta, \psi)$, dicha ignorabilidad se logra cuando $\pi(\theta, \psi) = \pi(\theta)\pi(\psi)$. Es decir, si en la *a priori* se pide indistinguibilidad de los parámetros (i.e. que θ y ψ sean independientes), entonces el mecanismo es ignorable para inferir θ .

Solución del problema 7.

Solución del problema 8. Dado que $a > 0$, se tiene que

$$\min(y) := \min_{1 \leq i \leq n} y_i = \min_{1 \leq i \leq n} (ax_i + b) = b + \min_{1 \leq i \leq n} (ax_i) = b + a \min_{1 \leq i \leq n} x_i = a \min(x) + b.$$

De manera análoga,

$$\max(y) := \max_{1 \leq i \leq n} y_i = \max_{1 \leq i \leq n} (ax_i + b) = b + \max_{1 \leq i \leq n} (ax_i) = b + a \max_{1 \leq i \leq n} x_i = a \max(x) + b.$$

Por consiguiente, para todo $i \in \{1, \dots, n\}$, se tiene que

$$y_i^* = \frac{y_i - \min(y)}{\max(y) - \min(y)} = \frac{(ax_i + b) - (a \min(x) + b)}{(a \max(x) + b) - (a \min(x) + b)} = \frac{a(x_i - \min(x))}{a(\max(x) - \min(x))} = x_i^*,$$

que es lo deseado.

Solución del problema 9. (a) Como el soporte de X es $[x_m, \infty)$, con $x_m > 0$, la transformación $Y = \log(X)$ está bien definida, y Y tiene soporte en $[\log(x_m), \infty)$. Además, la función $g(x) = \log(x)$ definida en \mathbb{R}^+ es uno a uno y tiene inversa $g^{-1}(y) = e^y$, la cual es una función derivable, con $\frac{d}{dy}g^{-1}(y) = e^y$. Por lo tanto, como se cumple la relación $Y = \log(X)$ y por consiguiente $X = e^Y$, por el Teorema de Cambio de Variables Y tiene densidad dada por

$$f_Y(y) = \left| \frac{dx}{dy} \right| f_X(e^y) \mathbb{1}_{[\log(x_m), \infty)}(y) = e^y \frac{\alpha x_m^\alpha}{e^{y(\alpha+1)}} \mathbb{1}_{[\log(x_m), \infty)}(y) = \alpha \left(\frac{x_m}{e^y} \right)^\alpha \mathbb{1}_{[\log(x_m), \infty)}(y).$$

Notemos que esta última expresión puede ser escrita como

$$f_Y(y) = \alpha e^{-\alpha(y - \log(x_m))} \mathbb{1}_{[0, \infty)}(y - \log(x_m)),$$

de donde se puede observar que $Y \stackrel{d}{=} \log(x_m) + \text{Exp}(\alpha)$, en donde $\text{Exp}(\alpha)$ es una variable aleatoria con distribución exponencial de media $\frac{1}{\alpha}$. En particular, de aquí se sigue que la función de distribución acumulada de Y es

$$F_Y(y) = \begin{cases} 0, & \text{si } y < \log(x_m), \\ 1 - e^{-\alpha(y - \log(x_m))}, & \text{si } y \geq \log(x_m). \end{cases}$$

(b) Primero veamos que, dado $x > x_m$,

$$\mathbb{P}[X \geq x] = \int_x^\infty \frac{\alpha x_m^\alpha}{t^{\alpha+1}} dt = x_m^\alpha [-t^{-\alpha}]_{t=x}^\infty = \left(\frac{x_m}{x} \right)^\alpha.$$

De este modo, la cola de X decae de forma polinomial, del orden $x^{-\alpha}$. Por otro lado, si $y > \log(x_m)$,

$$\mathbb{P}[Y \geq y] = e^{\alpha \log(x_m)} e^{-\alpha y} = x_m^\alpha e^{-\alpha y},$$

de donde podemos ver que la cola de Y decae de forma polinomial, del orden $e^{-\alpha y}$ (más rápidamente que el decaimiento polinomial). Es decir, X tiene colas más pesadas, y al transformarse a Y , cambia a colas más ligeras.

(c) Notemos que, como $Y = \log(X)$, para todo $y \in \mathbb{R}$ se cumple que

$$\mathbb{P}[Y > y] = \mathbb{P}[X > e^y],$$

de modo que, como e^y crece más rápido que y , las colas de Y decaen más rápidamente de las de X , como lo visto con la distribución Pareto, en donde un decaimiento polinomial se convierte en uno exponencial. Además, como la función logaritmo es creciente y $\log(x) \leq \log(x+1) \leq x$ para todo $x > 0$, por lo general Y tiene un soporte más grande que X .

Más aún, por las propiedades de la función logarítmica, los cambios grandes en X se reflejan en cambios más chicos de Y . Por ejemplo, si un valor de X se duplica, en la transformación logarítmica el valor de Y solo incrementa en $\log 2$ (cambios multiplicativos se transforman en

cambios aditivos). Por consiguiente, si X tiene colas muy pesadas, Y tiende a distribuir el peso a lo largo de los reales y no tan concentrado en las colas; es decir, se “acortan” las colas largas. Además esto produce, por lo general, distribuciones más cercanas a la simetría, en especial cuando hay errores multiplicativos, que se convierten en errores aditivos al aplicar logaritmo, y el Teorema del Límite Central explica dicha simetría.

Solución del problema 10.

Solución del problema 11. (a) Sea $x > 0$, y veamos que

$$\lim_{\lambda \rightarrow 0} (x^\lambda - 1) = 1 - 1 = 0,$$

mientras que $\lim_{\lambda \rightarrow 0} \lambda = 0$. Además, la función $\lambda \mapsto x^\lambda$ es derivable, con derivada igual a $\lambda x^{\lambda-1} (\neq 0)$. Por lo tanto, ya que el siguiente límite existe, por la Regla de l'Hôpital se tiene que

$$\log(x) = \lim_{\lambda \rightarrow 0} \frac{\log(x)x^\lambda}{\lambda} = \lim_{\lambda \rightarrow 0} \frac{x^\lambda - 1}{\lambda} = \lim_{\lambda \rightarrow 0} y(\lambda).$$

(b) Consideremos a la sucesión $(x_n)_{n \in \mathbb{N}}$, en donde $x_n = 2^n$ para todo $n \in \mathbb{N}$. Dicha sucesión toma valores muy dispersos cuando n es muy grande, pues sus primeros valores son

2, 4, 8, 16, 32, 64, 128, 256, 512, 1024, 2048, 4096, 8192, 16384, 32768, 65536, 131072, 262144, ...

La sucesión correspondiente a la transformación de Box y Cox con $\lambda = 1$ es la misma pero recorrida en 1, así que sigue siendo igual de dispersa. Sin embargo, con la transformación logarítmica ($\lambda = 0$), se convierte en $(y_n)_{n \in \mathbb{N}}$, en donde $y_n = n \log(2)$ para todo $n \in \mathbb{N}$, que es mucho menos dispersa. A manera de ilustración, sus primeros valores son aproximadamente iguales a:

0.6931, 1.3863, 2.0794, 2.7726, 3.4657, 4.1589, 4.852, 5.5452, 6.2383, 6.9315, 7.6246, 8.3178, 9.0109, ...

Solución del problema 12. a)- Con las hipótesis del enunciado, observe que la función $\hat{f}_h(x)$ es una suma de funciones indicadoras, que cuenta el número de observaciones x_i que están en el mismo conjunto que x , I_j . Luego ya que $1\{x_i \in I_j\} \geq 0$ y $nh > 0$ se tiene que $\hat{f}_h(x) \geq 0$.

b)- Para dar respuesta a este inciso, observe que la función $\hat{f}_h(x)$ se puede escribir como,

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n 1\{x_i \in I_j\} 1\{x \in I_j\}.$$

Luego la integral buscada se puede ver como,

$$\begin{aligned} \int_{-\infty}^{\infty} \hat{f}_h(x) dx &= \int_{-\infty}^{\infty} \frac{1}{nh} \sum_{i=1}^n 1\{x_i \in I_j\} 1\{x \in I_j\} dx \\ &= \sum_{j=1}^k \frac{1}{nh} \sum_{i=1}^n 1\{x_i \in I_j\} \int_{-\infty}^{\infty} 1\{x \in I_j\} dx \\ &= \sum_{j=1}^k \frac{1}{nh} \sum_{i=1}^n 1\{x_i \in I_j\} \int_{I_j} dx \\ &= \sum_{j=1}^k \frac{1}{nh} \sum_{i=1}^n 1\{x_i \in I_j\} \cdot h \\ &= \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^k 1\{x_i \in I_j\} \\ &= \frac{1}{n} \sum_{i=1}^n 1 \\ &= \frac{n}{n} = 1. \end{aligned}$$

Donde la segunda igualdad se tiene de considerar la partición I_1, \dots, I_k , la penúltima igualdad se tiene ya que cada x_i pertenece a algún conjunto I_j .

c)-Observe que cuando h es grande, los intervalos contendrán más datos, esto nos llevará a que no se aprecie si hay algún patrón en el comportamiento de los datos, es decir si los datos tienen preferencia por ciertos intervalos. Por otro lado, cuando h es muy pequeño, los intervalos no alcanzarán a contener muchos datos, un caso extremo de ver esto es hacer a h muy cercano a cero de tal forma que cada intervalo contenga a lo más un dato, en este caso, solo se verán barras de tamaño $\frac{1}{n}$ en cada dato.

Solución del problema 13. Normalización)- Con las hipótesis del enunciado, observe que la integral se puede escribir como,

$$\begin{aligned}\int_{-\infty}^{\infty} \hat{f}_h(x) dx &= \int_{-\infty}^{\infty} \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) dx \\&= \sum_{i=1}^n \frac{1}{nh} \int_{-\infty}^{\infty} K\left(\frac{x-x_i}{h}\right) dx \\&= \sum_{i=1}^n \frac{1}{nh} \int_{-\infty}^{\infty} K(u) h du \\&= \sum_{i=1}^n \frac{1}{n} \int_{-\infty}^{\infty} K(u) du \\&= \sum_{i=1}^n \frac{1}{n} = 1.\end{aligned}$$

Donde la tercer igualdad se tiene haciendo el cambio de variable $u = \frac{x-x_i}{h}$ y la penúltima igualdad se tiene gracias a que la integral del kernel K es uno.

No negatividad)- Para este inciso basta observar por hipotesis $K(u) \geq 0$ y que $nh > 0$ por lo que $\hat{f}_h(x) \geq 0$.

Sesgo puntual)- Observe que el sesgo puntual se puede escribir como,

$$\begin{aligned}\mathbb{E} [\hat{f}_h(x)] - f(x) &= \mathbb{E} \left[\sum_{i=1}^n \frac{1}{nh} K\left(\frac{x-x_i}{h}\right) \right] - f(x) \\&= \sum_{i=1}^n \frac{1}{nh} \mathbb{E} \left[K\left(\frac{x-x_i}{h}\right) \right] - f(x) \\&= \frac{1}{h} \mathbb{E} \left[K\left(\frac{x-x_1}{h}\right) \right] - f(x) \\&= \frac{1}{h} \int_{-\infty}^{\infty} K\left(\frac{x-x_1}{h}\right) f(x_1) dx_1 - f(x).\end{aligned}$$

Haciendo el cambio de variable $u = \frac{x-x_1}{h}$ y considerando que la integral del kernel es igual a uno, se tiene que la expresión anterior es igual a,

$$\begin{aligned}&\frac{1}{h} \int_{-\infty}^{\infty} h K(u) f(x-uh) du - \int_{-\infty}^{\infty} K(u) f(x) du \\&= \int_{-\infty}^{\infty} K(u) [f(x-uh) - f(x)] du.\end{aligned}$$

Por otro lado, observe que si se desarrolla la serie de Taylor de orden dos de $f(x - uh)$ al rededor de x con error de Peano se tiene la siguiente expresión,

$$f(x - uh) = f(x) + f'(x)(x - uh - x) + \frac{f''(x)(x - uh - x)^2}{2!} + h_2(x - uh)(uh)^2, \quad \lim_{x - uh \rightarrow x} h_2(x - uh) = 0,$$

de donde se puede despejar la expresión $f(x - uh) - f(x)$ y sustituyendo en la integral se tiene,

$$\begin{aligned} & \int_{-\infty}^{\infty} K(u) \left[f'(x)(-uh) + \frac{f''(x)(uh)^2}{2!} + h_2(x - uh)(uh)^2 \right] du \\ &= \frac{f''(x)}{2!} h^2 \int_{-\infty}^{\infty} u^2 K(u) du + h^2 \int_{-\infty}^{\infty} K(u) h_2(x - uh) u^2 du, \end{aligned}$$

donde esta última igualdad se tiene ya que el primer momento es cero. Además, observe que si se divide entre h^2 a la expresión de la derecha y se hace tender a h a cero se tiene,