

# TAREA 1

## CIENCIA DE DATOS

**Brain de Jesús Salazar, César Ávila, Iván García**

12 de septiembre de 2025

Solución del problema 1.

**Solución del problema 2.**

### Solución del problema 3.

**Solución del problema 4.**

**Solución del problema 5.** Consideremos una muestra  $Y_1, \dots, Y_n$  de variables aleatorias independientes e idénticamente distribuidas con media  $\mu$  y varianza  $\sigma^2$ , con indicadores  $R_i \in \{0, 1\}$ , de tal manera que  $R_i \perp Y_i$  para cada  $i \in \{1, \dots, n\}$ . Dichas  $R_i$  existen pues estamos bajo el modelo MCAR, y se interpretan como  $R_i = 1$  si y solo si el dato  $Y_i$  fue observado.

Notemos que si  $n_{obs}$  representa el número de datos observados, entonces  $n_{obs} = \sum_{i=1}^n R_i$ . Además, por la definición de los  $R_i$ ,

$$\bar{Y}_{obs} = \frac{1}{n_{obs}} \sum_{i=1}^n R_i Y_i = \frac{1}{n_{obs}} \sum_{i: R_i=1} Y_i.$$

Así pues, si  $\mathbf{R} = (R_1, \dots, R_n)$ , entonces

$$\begin{aligned} \mathbb{E} [\bar{Y}_{obs} | \mathbf{R}] &= \mathbb{E} \left[ \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n R_i Y_i \middle| \mathbf{R} \right] = \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n \mathbb{E} [R_i Y_i | \mathbf{R}] \\ &= \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n R_i \mathbb{E} [Y_i | \mathbf{R}] \\ &= \frac{1}{\sum_{i=1}^n R_i} \sum_{i=1}^n R_i \mathbb{E} [Y_i] \\ &= \mu, \end{aligned}$$

en donde hemos usado que las  $Y_i$  son iid con media  $\mu$  y son independientes de  $\mathbf{R}$  (por las hipótesis del modelo MCAR). Por consiguiente,

$$\mathbb{E} [\bar{Y}_{obs}] = \mathbb{E} [\mathbb{E} [\bar{Y}_{obs} | \mathbf{R}]] = \mu.$$

Por otra parte,

$$\bar{Y}_{obs}^2 = \frac{1}{(\sum_{i=1}^n R_i)^2} \left[ \sum_{i=1}^n R_i^2 Y_i^2 + \sum_{i \neq j} R_i R_j Y_i Y_j \right],$$

por lo que

$$\begin{aligned} \mathbb{E} [\bar{Y}_{obs}^2 | \mathbf{R}] &= \frac{1}{(\sum_{i=1}^n R_i)^2} \left[ \sum_{i=1}^n R_i^2 \mathbb{E} [Y_i^2 | \mathbf{R}] + \sum_{i \neq j} R_i R_j \mathbb{E} [Y_i Y_j | \mathbf{R}] \right] \\ &= \frac{1}{(\sum_{i=1}^n R_i)^2} \left[ \sum_{i=1}^n R_i^2 \mathbb{E} [Y_i^2] + \sum_{i \neq j} R_i R_j \mathbb{E} [Y_i Y_j] \right] \\ &= \frac{1}{(\sum_{i=1}^n R_i)^2} \left[ (\sigma^2 + \mu^2) \sum_{i=1}^n R_i^2 + \mu^2 \sum_{i \neq j} R_i R_j \right] \\ &= \mu^2 + \sigma^2 \frac{\sum_{i=1}^n R_i^2}{(\sum_{i=1}^n R_i)^2}. \end{aligned}$$

De lo anterior se sigue que

$$\begin{aligned}
\text{Var} [\bar{Y}_{obs}] &= \mathbb{E} [\bar{Y}_{obs}^2] - (\mathbb{E} [\bar{Y}_{obs}])^2 = \mathbb{E} [\mathbb{E} [\bar{Y}_{obs}^2 \mid \mathbf{R}]] - \mu^2 = \sigma^2 \mathbb{E} \left[ \frac{\sum_{i=1}^n R_i^2}{(\sum_{i=1}^n R_i)^2} \right] \\
&= \sigma^2 \mathbb{E} \left[ \frac{\sum_{i=1}^n R_i}{(\sum_{i=1}^n R_i)^2} \right] \\
&= \sigma^2 \mathbb{E} \left[ \frac{1}{\sum_{i=1}^n R_i} \right] \\
&= \sigma^2 \mathbb{E} \left[ \frac{1}{n_{obs}} \right] \\
&\geq \frac{\sigma^2}{n} = \text{Var} [\bar{Y}] ,
\end{aligned}$$

en donde hemos usado que  $R_i^2 = R_i$ , pues  $R_i \in \{0, 1\}$ , para todo  $i \in \{1, \dots, n\}$ , y que  $n_{obs} \leq n$ . De hecho, siguiendo un procedimiento completamente análogo, pero ahora con varianzas condicionales, se sigue que

$$\text{Var} [\bar{Y}_{obs} \mid \mathbf{R}] = \frac{\sigma^2}{n_{obs}}.$$

De lo anterior podemos notar que  $\bar{Y}_{obs}$  es insesgado, pero que  $\text{Var} [\bar{Y}_{obs}] \geq \text{Var} [\bar{Y}]$ , por lo que  $\bar{Y}_{obs}$  tiene menor eficiencia (posee más varianza, pues la eliminación de datos hace que haya menos de ellos para poder estimar a la media de  $Y$ ).

**Solución del problema 6.** Sean  $\mathbf{Y} = (Y_{obs}, Y_{mis})$  y  $\mathbf{R}$  el patrón de datos faltantes. Bajo la definición del MAR,

$$\mathbb{P}[\mathbf{R} | Y_{obs}, Y_{mis}, \theta, \psi] = \mathbb{P}[\mathbf{R} | Y_{obs}, \psi].$$

Así pues, bajo este modelo,

$$\mathbb{P}[\mathbf{Y}, \mathbf{R} | \theta, \psi] = \mathbb{P}[\mathbf{Y} | \theta] \mathbb{P}[\mathbf{R} | \mathbf{Y}, \psi] = \mathbb{P}[\mathbf{Y} | \theta] \mathbb{P}[\mathbf{R} | Y_{obs}, \psi].$$

Por consiguiente, la verosimilitud de  $\theta$  está dada por

$$\begin{aligned} L(\theta; Y_{obs}, \mathbf{R}) &= \int \mathbb{P}[\mathbf{Y}, \mathbf{R} | \theta, \psi] dY_{mis} = \int \mathbb{P}[\mathbf{Y} | \theta] \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] dY_{mis} \\ &= \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \int \mathbb{P}[\mathbf{Y} | \theta] dY_{mis} \\ &= \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \mathbb{P}[Y_{obs} | \theta]. \end{aligned}$$

Ya que el factor  $\mathbb{P}[\mathbf{R} | Y_{obs}, \psi]$  no depende de  $\theta$ , se sigue que  $L(\theta; Y_{obs}, \mathbf{R}) \propto \mathbb{P}[Y_{obs} | \theta]$ . Para ver las condiciones *a priori* que garantizan ignorabilidad bajo el enfoque bayesiano, notemos que

$$\begin{aligned} \mathbb{P}[\theta | Y_{obs}, \mathbf{R}] &= \int \mathbb{P}[\theta, \psi | Y_{obs}, \mathbf{R}] d\psi \propto \int \mathbb{P}[Y_{obs}, \mathbf{R} | \theta, \psi] \pi(\theta, \psi) d\psi \\ &= \int \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \mathbb{P}[Y_{obs} | \theta] \pi(\theta, \psi) d\psi \\ &= \mathbb{P}[Y_{obs} | \theta] \int \mathbb{P}[\mathbf{R} | Y_{obs}, \psi] \pi(\theta, \psi) d\psi. \end{aligned}$$

Para concluir ignorabilidad buscamos que  $L(\theta | Y_{obs}, \mathbf{R}) \propto \pi(\theta) \mathbb{P}[Y_{obs} | \theta]$ , y ya que la integral anterior depende de  $\theta$  solamente a través del factor  $\pi(\theta, \psi)$ , dicha ignorabilidad se logra cuando  $\pi(\theta, \psi) = \pi(\theta)\pi(\psi)$ . Es decir, si en la *a priori* se pide indistinguibilidad de los parámetros (i.e. que  $\theta$  y  $\psi$  sean independientes), entonces el mecanismo es ignorable para inferir  $\theta$ .

## Solución del problema 7.



**Solución del problema 8.** Dado que  $a > 0$ , se tiene que

$$\min(y) := \min_{1 \leq i \leq n} y_i = \min_{1 \leq i \leq n} (ax_i + b) = b + \min_{1 \leq i \leq n} (ax_i) = b + a \min_{1 \leq i \leq n} x_i = a \min(x) + b.$$

De manera análoga,

$$\max(y) := \max_{1 \leq i \leq n} y_i = \max_{1 \leq i \leq n} (ax_i + b) = b + \max_{1 \leq i \leq n} (ax_i) = b + a \max_{1 \leq i \leq n} x_i = a \max(x) + b.$$

Por consiguiente, para todo  $i \in \{1, \dots, n\}$ , se tiene que

$$y_i^* = \frac{y_i - \min(y)}{\max(y) - \min(y)} = \frac{(ax_i + b) - (a \min(x) + b)}{(a \max(x) + b) - (a \min(x) + b)} = \frac{a(x_i - \min(x))}{a(\max(x) - \min(x))} = x_i^*,$$

que es lo deseado.

**Solución del problema 9.** (a) Como el soporte de  $X$  es  $[x_m, \infty)$ , con  $x_m > 0$ , la transformación  $Y = \log(X)$  está bien definida, y  $Y$  tiene soporte en  $[\log(x_m), \infty)$ . Además, la función  $g(x) = \log(x)$  definida en  $\mathbb{R}^+$  es uno a uno y tiene inversa  $g^{-1}(y) = e^y$ , la cual es una función derivable, con  $\frac{d}{dy}g^{-1}(y) = e^y$ . Por lo tanto, como se cumple la relación  $Y = \log(X)$  y por consiguiente  $X = e^Y$ , por el Teorema de Cambio de Variables  $Y$  tiene densidad dada por

$$f_Y(y) = \left| \frac{dx}{dy} \right| f_X(e^y) \mathbb{1}_{[\log(x_m), \infty)}(y) = e^y \frac{\alpha x_m^\alpha}{e^{y(\alpha+1)}} \mathbb{1}_{[\log(x_m), \infty)}(y) = \alpha \left( \frac{x_m}{e^y} \right)^\alpha \mathbb{1}_{[\log(x_m), \infty)}(y).$$

Notemos que esta última expresión puede ser escrita como

$$f_Y(y) = \alpha e^{-\alpha(y - \log(x_m))} \mathbb{1}_{[0, \infty)}(y - \log(x_m)),$$

de donde se puede observar que  $Y \stackrel{d}{=} \log(x_m) + \text{Exp}(\alpha)$ , en donde  $\text{Exp}(\alpha)$  es una variable aleatoria con distribución exponencial de media  $\frac{1}{\alpha}$ . En particular, de aquí se sigue que la función de distribución acumulada de  $Y$  es

$$F_Y(y) = \begin{cases} 0, & \text{si } y < \log(x_m), \\ 1 - e^{-\alpha(y - \log(x_m))}, & \text{si } y \geq \log(x_m). \end{cases}$$

(b) Primero veamos que, dado  $x > x_m$ ,

$$\mathbb{P}[X \geq x] = \int_x^\infty \frac{\alpha x_m^\alpha}{t^{\alpha+1}} dt = x_m^\alpha [-t^{-\alpha}]_{t=x}^\infty = \left( \frac{x_m}{x} \right)^\alpha.$$

De este modo, la cola de  $X$  decae de forma polinomial, del orden  $x^{-\alpha}$ . Por otro lado, si  $y > \log(x_m)$ ,

$$\mathbb{P}[Y \geq y] = e^{\alpha \log(x_m)} e^{-\alpha y} = x_m^\alpha e^{-\alpha y},$$

de donde podemos ver que la cola de  $Y$  decae de forma polinomial, del orden  $e^{-\alpha y}$  (más rápidamente que el decaimiento polinomial). Es decir,  $X$  tiene colas más pesadas, y al transformarse a  $Y$ , cambia a colas más ligeras.

(c) Notemos que, como  $Y = \log(X)$ , para todo  $y \in \mathbb{R}$  se cumple que

$$\mathbb{P}[Y > y] = \mathbb{P}[X > e^y],$$

de modo que, como  $e^y$  crece más rápido que  $y$ , las colas de  $Y$  decaen más rápidamente de las de  $X$ , como lo visto con la distribución Pareto, en donde un decaimiento polinomial se convierte en uno exponencial. Además, como la función logaritmo es creciente y  $\log(x) \leq \log(x+1) \leq x$  para todo  $x > 0$ , por lo general  $Y$  tiene un soporte más grande que  $X$ .

Más aún, por las propiedades de la función logarítmica, los cambios grandes en  $X$  se reflejan en cambios más chicos de  $Y$ . Por ejemplo, si un valor de  $X$  se duplica, en la transformación logarítmica el valor de  $Y$  solo incrementa en  $\log 2$  (cambios multiplicativos se transforman en

cambios aditivos). Por consiguiente, si  $X$  tiene colas muy pesadas,  $Y$  tiende a distribuir el peso a lo largo de los reales y no tan concentrado en las colas; es decir, se “acortan” las colas largas. Además esto produce, por lo general, distribuciones más cercanas a la simetría, en especial cuando hay errores multiplicativos, que se convierten en errores aditivos al aplicar logaritmo, y el Teorema del Límite Central explica dicha simetría.

**Solución del problema 10.**

**Solución del problema 11.** (a) Sea  $x > 0$ , y veamos que

$$\lim_{\lambda \rightarrow 0} (x^\lambda - 1) = 1 - 1 = 0,$$

mientras que  $\lim_{\lambda \rightarrow 0} \lambda = 0$ . Además, la función  $\lambda \mapsto x^\lambda$  es derivable, con derivada igual a  $\lambda x^{\lambda-1} (\neq 0)$ . Por lo tanto, ya que el siguiente límite existe, por la Regla de l'Hôpital se tiene que

$$\log(x) = \lim_{\lambda \rightarrow 0} \frac{\log(x)x^\lambda}{\lambda} = \lim_{\lambda \rightarrow 0} \frac{x^\lambda - 1}{\lambda} = \lim_{\lambda \rightarrow 0} y(\lambda).$$

(b) Consideremos a la sucesión  $(x_n)_{n \in \mathbb{N}}$ , en donde  $x_n = 2^n$  para todo  $n \in \mathbb{N}$ . Dicha sucesión toma valores muy dispersos cuando  $n$  es muy grande, pues sus primeros valores son

2, 4, 8, 16, 32, 64, 128, 256, 512, 1024, 2048, 4096, 8192, 16384, 32768, 65536, 131072, 262144, ...

La sucesión correspondiente a la transformación de Box y Cox con  $\lambda = 1$  es la misma pero recorrida en 1, así que sigue siendo igual de dispersa. Sin embargo, con la transformación logarítmica ( $\lambda = 0$ ), se convierte en  $(y_n)_{n \in \mathbb{N}}$ , en donde  $y_n = n \log(2)$  para todo  $n \in \mathbb{N}$ , que es mucho menos dispersa. A manera de ilustración, sus primeros valores son aproximadamente iguales a:

0.6931, 1.3863, 2.0794, 2.7726, 3.4657, 4.1589, 4.852, 5.5452, 6.2383, 6.9315, 7.6246, 8.3178, 9.0109, ...

**Solución del problema 12.**

### Solución del problema 13.